Anchr RAG 与 Agent 运行规则

传统 RAG 与回答模式

D002 | anchr-seed-v1.0.0 | 固定快照 2026-09-07

14. 传统 RAG

Agent 关闭或 Agent 异常降级时，`KB_QUERY` 执行：

Query Rewrite

-> Unified Retrieval

-> Result Card Mapping

-> 选择最多 5 个可追溯候选

-> Citation Mapping

-> Grounded Answer Generation

-> 只保留答案实际使用的 Citation

-> 生成引用原因

回答模式：

模式	Grounding 数	最少证据字符	最低 Top Score	是否允许推测
`STRICT`	5	80	0.12	否
`SUMMARY`	3	60	0.10	否
`EXPLORE`	5	40	0.08	是，且必须明确标注

传统答案模型必须输出 `ANSWERED|NO_EVIDENCE` 严格 JSON，并使用 `[1]` 引用输入证据。后端校验引用范围、规范化文档索引，并只保留答案真正使用的 Segment。

运行配置 `CONVERSATION.legacyEvidenceFallbackEnabled` 默认是 `false`。模型失败或格式不合法时，默认返回 `GENERATION_FAILED`；启用该配置后才使用证据拼接旧式保守答案。

来源：agent-rag-workflow.md 第 653-679 行

Anchr RAG 与 Agent 运行规则

异步总结限制与配置生效时机

D002 | anchr-seed-v1.0.0 | 固定快照 2026-09-07

10.1 默认限制

限制	默认值
文档数	1–3
最大 Segment 数	500
最大正文字符	500000
Map/Reduce 批次字符	12000
任务总时限	10 分钟
单次总结模型时限	90 秒
Lease	2 分钟
最大重试	2
轮询间隔	5 秒

16. 关键配置

Agent 的开关、工具模式、预算、超时、异步重试和大部分总结限制使用Settings 中的 `AGENT` 运行配置。Conversation 的传统证据降级使用`CONVERSATION.legacyEvidenceFallbackEnabled`。同步 Run 在初始化时读取并冻结配置；异步 Task 每次被 Claim 并开始一个执行 attempt 时重新读取配置，因此同一 Task 的后续重试可能使用更新后的配置，但单个 attempt 内不会变化。

文档总结数量目前仍由代码常量固定为 1–3 份。Settings Catalog 虽然包含 `AGENT.summaryMaxDocuments`，但 `AgentRuntimeSettings`、`SummarizeDocumentsTool` 和 `AgentTaskProcessor` 当前都使用固定值 3，因此该配置项尚未实际控制运行行为。

异步任务 Lease 固定为 2 分钟，Claim 轮询间隔固定为 5 秒，不接受外部配置。

来源：agent-rag-workflow.md 第 489-501 行；agent-rag-workflow.md 第 735-747 行

Anchr RAG 与 Agent 运行规则

状态来源与安全边界

D002 | anchr-seed-v1.0.0 | 固定快照 2026-09-07

12.3 状态来源

- MySQL 中的 Conversation、Agent Run、Agent Step 和 Agent Task 是权威数据。

- Redis Runtime Snapshot 是 best-effort 缓存；读写失败不得影响主工作流。

- Snapshot 使用单调递增 `version`，客户端可以用 `afterVersion` 避免重复获取旧快照。

- 默认 TTL 为 35 分钟；实际 TTL 取配置值与“任务总时限 × 最大尝试次数 + 5 分钟”中的较大值。

- 可恢复列表最多返回 20 条，优先活动状态 `RUNNING/WAITING_TASK/AWAITING_TURN`，并包含最近 10 分钟启动的终态 Run。

- Conversation 与 Task 共用的 Answer Event Broker 只覆盖单 JVM。当前系统只支持单 App 实例；Task/Turn 轮询和 Runtime Snapshot 用于客户端断线或进程重启后的恢复，不是多实例部署的一致性方案。

15.2 安全与可靠性

1. 用户输入、历史消息、文档正文和工具结果都视为不可信数据。

2. 模型只能调用注册工具，不能扩大 KB/Asset 权限。

3. 文档工具必须通过服务端范围校验，不能相信模型提供的 ID。

4. KNOWLEDGE 只能引用当前 Run 的 Evidence Registry。

5. 后端拒绝模型伪造的数字引用，只把合法 Segment Marker 渲染为可见引用。

6. 异步任务使用 Lease、Owner 和条件更新防止重复认领与重复写入；这是任务并发保护，不代表整个应用支持多实例部署。

7. Agent Run 创建前和 Turn 保存前都会锁定未删除会话，避免会话删除与 Run/回答落库竞态。

8. 异步阶段分配 Trace Order 时锁定 Run；Run 不存在时跳过写入，避免新增孤立 Step。

9. Run 与 Task 的终态更新校验预期源状态，避免并发完成、取消和迟到写入互相覆盖。

10. 删除会话时取消活动 Run/Task，并删除相关 Trace 与 Task 记录。

11. Redis 快照不参与权限或业务终态判断，MySQL 仍是权威来源。

来源：agent-rag-workflow.md 第 616-623 行；agent-rag-workflow.md 第 721-733 行